



**UNIVERSIDAD AUTÓNOMA DE YUCATÁN**

**FACULTAD DE MATEMATICAS**

**LICENCIATURA DE ACTUARIA**

---

Asignatura

Análisis de Supervivencia

**Proyecto Final**

**Profesor: José Luis Batún Cutz**

**Alumno: Mauricio Guillermo Becerril Rodriguez**

**Fecha de entrega:**

**4 de mayo del 2026**

## **INTRODUCCION**

### **Descripción e Importancia del Problema**

El presente proyecto aborda el análisis de la duración de contratos en una institución financiera enfocada en la comercialización de seguros de vida y planes de ahorro a largo plazo. El problema central radica en comprender e identificar los factores que influyen en la cancelación anticipada de dichos contratos por parte de los asegurados.

Dar solución a este problema es de vital importancia estratégica y técnica; la cancelación prematura de los productos representa un riesgo importante que impacta directamente en la rentabilidad esperada de la empresa y compromete la correcta gestión actuarial del portafolio de clientes.

### **Definición del Tiempo de Vida**

Para efectos de este modelo de supervivencia, el "tiempo de vida" se define como la duración del contrato, medida en meses, que transcurre desde el momento de la suscripción del producto hasta que ocurre su cancelación. En este estudio, el "evento" o "falla" está definido estrictamente como la cancelación anticipada del contrato (marcado con el indicador 1).

Dada la naturaleza longitudinal de los datos históricos recopilados, la muestra está sujeta a mecanismos de censura por la derecha (indicador de evento igual a 0). Esto implica que para un subconjunto de clientes, el evento de cancelación no se observó dentro de la ventana de análisis. Las situaciones empíricas que originan esta censura en la base de datos incluyen:

- **Censura administrativa (Fin del periodo de observación):** Constituye la causa principal, originada cuando el contrato del cliente se mantiene activo y sin alteraciones hasta el momento exacto en que se realiza el corte de la base de datos para este estudio.
- **Maduración del producto financiero:** Especialmente en los planes de ahorro a largo plazo, el contrato puede llegar a su fecha de vencimiento natural. El cliente retira sus fondos habiendo cumplido el plazo pactado, lo que extingue el riesgo de "cancelación anticipada".

- **Siniestralidad (Riesgo competitivo):** Tratándose de seguros de vida, el fallecimiento del titular obliga a la institución a liquidar la suma asegurada. Este suceso retira abruptamente al individuo de la población en riesgo, imposibilitando observar una eventual cancelación futura.

### ANÁLISIS DESCRIPTIVO

En primera instancia podemos observar el comportamiento de las estimaciones de las funciones de supervivencia para las dos categorías de la covariable “producto” que nos dice que tipo de producto adquirió el cliente ya sea “ahorro” o “seguro”.

Como podemos observar la **FIGURA 1** sugiere que se presenta cierta diferencia en la trayectoria del comportamiento de las curvas de supervivencia a lo largo del tiempo, aunque la curva correspondiente al “ahorro” llega a cero más rápido que su contraparte, de forma exploratoria se sugiere que puede haber un patrón sistemático entre poblaciones.




FIGURA 1

Para corroborar formalmente, usaremos una prueba de hipótesis (prueba log-rank) con un grado de significancia de  $\alpha = 0.05$ , contrastando:

$H_0: S_1(t) = S_2(t)$  para toda  $t > 0$

Las funciones de supervivencia son iguales entre si para toda  $t$  mayor a cero

$H_1: S_1(t_0) \neq S_2(t_0)$  para algún  $t_0 > 0$

Las funciones de supervivencia son diferentes entre si en algún momento

Donde  $S_1(t)$ : es la función de supervivencia para las personas que adquirieron el producto de “ahorro” y  $S_2(t)$ : es la función de supervivencia para las personas que adquirieron el producto de “seguro”. Se obtuvieron los siguientes resultados:

Dado que  $p - valor = 0.000001 < 0.05 = \alpha$ , se rechaza la hipótesis nula. Esto implica

```
survdifff(formula = seguro.surv ~ producto, data = seguro, rho = 1)

      N Observed Expected (O-E)^2/E (O-E)^2/V
producto=0 491    144    183      8.14    23.3
producto=1 509    199    161      9.28    23.3

Chisq= 23.3 on 1 degrees of freedom, p= 1e-06
```

que se tiene la suficiente evidencia para tomar la hipótesis alternativa como verdadera que las funciones de supervivencia son diferentes entre en algún momento.

En términos prácticos, esto significa que el tipo de producto influye en el tiempo hasta la cancelación del producto. El tipo de producto es un factor determinante en la duración del contrato. Existe un patrón sistemático donde, por ejemplo, los clientes de "ahorro" podrían ser más propensos a retirar sus fondos antes de tiempo en comparación con los de "seguro".

Tras confirmar que el producto "seguro" constituye una subpoblación distinta, se evaluó su ajuste a siete distribuciones teóricas mediante gráficos de probabilidad (**FIGURA 2.1**). Mientras que los modelos Gumbel, Pareto, Gamma y Gompertz mostraron desviaciones severas, y las distribuciones Lognormal y Log-logística presentaron fallas en los extremos, la **distribución de Weibull** exhibió una alineación óptima sobre la diagonal. Por lo tanto, se concluye que la subpoblación de seguros sigue un comportamiento paramétrico de tipo Weibull, minimizando las desviaciones sistemáticas en el modelado del tiempo de vida.




FIGURA 2.1




FIGURA 2.2

De forma análoga, se evaluó el ajuste de la subpoblación de **ahorro** mediante PP-plots sobre las mismas siete distribuciones (**FIGURA 2.2**). El diagnóstico visual descartó nuevamente los modelos Gumbel, Pareto, Gamma y Gompertz por falta de ajuste, así como las distribuciones Lognormal y Log-logística por desviaciones en los extremos. La **distribución de Weibull** ratificó su superioridad al presentar la mayor linealidad sobre la diagonal. En síntesis, se concluye que ambas subpoblaciones (seguro y ahorro) se modelan óptimamente bajo Weibull, sugiriendo que la diferencia en su supervivencia radica en parámetros de forma y escala distintos. Por lo tanto se creará una nueva covariable a partir de la variable producto "dummie" que llamaremos "prodse" que nos indica si el cliente pertenece a la subpoblación de clientes que tienen el producto "seguro".

Análogamente analizaremos el comportamiento de las estimaciones de las funciones de supervivencia para las dos categorías de la covariable "educación" que nos dice que el nivel educativo del cliente en este caso (baja, media, alta)

Como podemos observar la **FIGURA 2** sugiere que se presenta cierta diferencia en la trayectoria del comportamiento de las curvas de supervivencia a lo largo del tiempo, en ese este caso son mínimas, aunque las curvas correspondientes al “educación media” y “educación baja” parecen ser muy similares y a la vez significativamente diferentes a la curva correspondiente a la “educación alta”. De forma exploratoria, se sugiere que puede haber un patrón sistemático entre poblaciones.

Para corroborar formalmente, usaremos una prueba de hipótesis (prueba log-rank) con un grado de significancia de  $\alpha = 0.05$ , contrastando:




FIGURA 2

$H_0: S_1(t) = S_2(t)$  para toda  $t > 0$

Las funciones de supervivencia son iguales entre sí para toda  $t$  mayor a cero, contextualmente,

$H_1: S_1(t_0) \neq S_2(t_0)$  para algún  $t_0 > 0$

Las funciones de supervivencia son diferentes entre si en algún momento

Donde  $S_1(t)$ : es la función de supervivencia para las personas que adquirieron el producto de “ahorro” y  $S_2(t)$ : es la función de supervivencia para las personas que adquirieron el producto de “seguro”. Se obtuvieron los siguientes resultados:

Dado que  $p - valor = 0.05$  que no es menor a  $0.05 = \alpha$ , no se rechaza la hipótesis nula. Esto implica

Que no se tiene la suficiente evidencia estadísticamente significativa en contra de que las funciones de supervivencia de ambas regiones sean

iguales, en términos prácticos, la probabilidad de mantener el contrato activo a lo largo del tiempo es igual para todos los clientes, sin importar su nivel de estudios.

```
survdif(formula = seguro.surv ~ educacion, data = seguro, rho = 1)
```

|             | N   | Observed | Expected | (O-E)^2/E | (O-E)^2/V |
|-------------|-----|----------|----------|-----------|-----------|
| educacion=0 | 341 | 109      | 123      | 1.592     | 3.323     |
| educacion=1 | 314 | 101      | 105      | 0.167     | 0.321     |
| educacion=2 | 345 | 133      | 115      | 2.870     | 5.769     |

Chisq= 6.2 on 2 degrees of freedom, p= 0.05

MODELO COX

Se ajustó un modelo de Cox considerando inicialmente todas las covariables especificadas: edad, ingreso, antigüedad, prodse, canal, educacion. Se realizó una prueba de hipótesis y los resultados que arrojó el modelo global que se estimó fue:

$H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$

vs

$H_1: \text{Existe al menos una } \beta_i \neq 0 \text{ con } i = 1, 2, 3, 4, 5, 6, 7$

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

exp(coef) exp(-coef) lower .95 upper .95
edad      1.0308    0.9702    1.0228    1.0387
antigüedad 0.9323    1.0726    0.9173    0.9475
prodseTRUE 0.6043    1.6549    0.5070    0.7201
ingreso    0.9999    1.0001    0.9999    1.0000
canal      0.9586    1.0432    0.8055    1.1408

Concordance= 0.67 (se = 0.013 )
Likelihood ratio test= 172.1 on 5 df, p=<2e-16
Wald test              = 169.1 on 5 df, p=<2e-16
Score (logrank) test = 173.2 on 5 df, p=<2e-16
```

Donde cada  $\beta_i$  corresponde a una covariable (edad, ingreso, canal, antigüedad, educación, prodse) Con un nivel de significancia de  $\alpha = 0.05$ , la prueba global del modelo mostró un  $p - \text{valor} < 2e - 16$  lo cual es menor a 0.05, es decir, se rechaza la hipótesis nula, indicando que, de manera conjunta, al menos una de las covariables explica de forma significativa el riesgo de ocurrencia del primer siniestro. Por lo tanto, el modelo de Cox es adecuado para continuar con el proceso de selección.

## PASO 1: PRUEBAS INDIVIDUALES

A partir del modelo anterior, se revisaron las significancias individuales considerando que todas las demás covariables permanecen en el modelo, aplicando el algoritmo correspondiente:

```
coxph(formula = Surv(tiempo, evento) ~ edad, data = seguro, na.action =
method = "breslow")

coef exp(coef) se(coef)      z      p
edad 0.025741  1.026075 0.003914 6.577 4.79e-11
```

Analizando la covariable **edad**, vemos que sí es significativa dado que las demás covariables están en el modelo debido a que su  $p - \text{valor} = 3.79e - 11 < 0.05$ , por lo tanto, es significativa y se queda dentro del modelo. Esto resulta lógico ya que, a mayor edad, aumenta el riesgo de presentar una cancelación anticipada

Analizando el covariable **ingreso**, vemos que sí es significativa dado que las demás covariables están en el modelo debido a que su  $p - \text{valor} = 2.411e - 07 < 0.05$ , por lo tanto, es significativa y se queda dentro del modelo. Esto resulta lógico ya que, a mayor ingreso, podría disminuir el riesgo de presentar una cancelación anticipada ya que no representa un flujo fuerte.

```
coxph(formula = Surv(tiempo, evento) ~ ingreso, data = seguro,
na.action = na.exclude, method = "breslow")

coef exp(coef) se(coef)      z      p
ingreso -4.809e-05  1.000e+00 9.301e-06 -5.17 2.34e-07

Likelihood ratio test=26.67 on 1 df, p=2.411e-07
n= 1000, number of events= 513
```


Analizando la covariable **educacion**, vemos que sí es significativa dado que las demás covariables

```
coxph(formula = Surv(tiempo, evento) ~ educacion, data = seguro,
na.action = na.exclude, method = "breslow")

coef exp(coef) se(coef)      z      p
educacion 0.11754  1.12473 0.05315 2.212 0.027

Likelihood ratio test=4.9 on 1 df, p=0.02682
n= 1000, number of events= 513
```





están en el modelo debido a que su  $p - valor = 0.002682 < 0.05$ , por lo tanto, es significativa y se queda dentro del modelo.

```
coef exp(coef) se(coef)      z      p
prodseTRUE -0.42477    0.65392  0.08922 -4.761 1.93e-06

Likelihood ratio test=22.91 on 1 df, p=1.7e-06
n= 1000, number of events= 513
```

Analizando el covariable **prodse**, que recordemos que es la nueva covariable que indica si pertenece o no a la subpoblación con el producto “seguro”, vemos que sí es significativa dado que las demás covariables están en el modelo debido a que su  $p - valor = 1.7e-06 < 0.05$ , por lo tanto, es significativa y se queda dentro del modelo. Esto resulta lógico ya que el tipo de producto podría disminuir o aumentar el riesgo de presentar una cancelación anticipada.

Analizando la covariable **antigüedad**, vemos que sí es significativa dado que las demás covariables están en el modelo debido a que su  $p - valor = 1.63e-13 < 0.05$ , por lo tanto, es significativa y se queda dentro del modelo.

```
Call:
coxph(formula = Surv(tiempo, evento) ~ antigüedad, data = seguro,
      na.action = na.exclude, method = "breslow")

      coef exp(coef) se(coef)      z      p
antigüedad -0.060250  0.941530  0.008168 -7.376 1.63e-13

Likelihood ratio test=54.89 on 1 df, p=1.27e-13
n= 1000, number of events= 513
```

Analizando la covariable **canal**, vemos que no es significativa debido a que su  $p - valor = 0.8923 > 0.05$ , por lo tanto, no es significativa y se queda fuera del modelo. Esto resulta lógico, ya que el medio desde donde se contrató el producto no debe influir ya que el producto es el mismo independientemente el canal en donde se adquiere.

```
Call:
coxph(formula = Surv(tiempo, evento) ~ canal, data = seguro,
      na.action = na.exclude, method = "breslow")

      coef exp(coef) se(coef)      z      p
canal -0.01200    0.98808  0.08856 -0.135 0.892

Likelihood ratio test=0.02 on 1 df, p=0.8923
n= 1000, number of events= 513
>
```

En resumen, vemos que las covariables que fueron significativas son:

- Edad
- Prodse (Indica si el cliente adquirió el producto “seguro”)
- Educacion
- Ingreso
- Antigüedad

Finalmente, se ajustó el modelo reducido utilizando únicamente las covariables significativas del paso anterior. El nuevo ajuste confirmó que nos quedamos por el momento con el modelo que incluyen a las covariables significativas individuales presentadas anteriormente. Las cuales siendo significativas dado que las otras ya están en el modelo.

## PASO 2: INTEGRACIÓN DE LAS COVARIABLES AL MODELO

```
Call:
coxph(formula = Surv(tiempo, evento) ~ edad + antigüedad + prodse +
      educacion + ingreso, data = seguro, na.action = na.exclude,
      method = "breslow")

n= 1000, number of events= 513

      coef exp(coef) se(coef)      z Pr(>|z|)
edad      2.973e-02  1.030e+00  3.944e-03  7.539 4.75e-14 ***
antigüedad -7.071e-02  9.317e-01  8.287e-03 -8.533 < 2e-16 ***
prodseTRUE -5.008e-01  6.061e-01  8.949e-02 -5.596 2.20e-08 ***
educacion  1.275e-01  1.136e+00  5.348e-02  2.385  0.0171 *
ingreso    -5.453e-05  9.999e-01  9.409e-06 -5.796 6.81e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

      exp(coef) exp(-coef) lower .95 upper .95
edad      1.0302    0.9707    1.0222    1.0382
antigüedad 0.9317    1.0733    0.9167    0.9470
prodseTRUE 0.6061    1.6500    0.5085    0.7222
educacion  1.1360    0.8803    1.0230    1.2616
ingreso    0.9999    1.0001    0.9999    1.0000

Concordance= 0.673 (se = 0.013 )
Likelihood ratio test= 177.6 on 5 df, p=<2e-16
Wald test = 174.8 on 5 df, p=<2e-16
Score (logrank) test = 179.3 on 5 df, p=<2e-16
```

El siguiente paso consistió en verificar si las covariables que resultaron significativas de manera individual (manteniendo a las demás dentro del modelo) permanecían siendo significativas cuando se incluían conjuntamente. En caso de que alguna perdiera significancia al formar parte del modelo reducido, el procedimiento indicado establece que debe eliminarse y volver a ajustar el modelo, repitiendo este proceso sucesivamente hasta obtener un conjunto en el que todas las covariables sean simultáneamente significativas.

Sin embargo, este no fue el caso: al ajustar el modelo con las covariables significativas del paso anterior. En este caso todas se mantuvieron significativas de manera conjunta, por lo que no fue necesario realizar eliminaciones adicionales.

### PASO 3

En este paso, el objetivo es evaluar si alguna de las covariables descartadas en el paso 1 (canal) podría aportar información significativa cuando se incorpora nuevamente al modelo. Para ello, se agregó individualmente al modelo reducido que contiene solo las covariables significativas. De esta manera se verifica si, al estar acompañadas por las covariables relevantes, si se vuelve significativa y, por lo tanto, debería reintegrarse al modelo final. En la imagen de la derecha podemos apreciar que sigue sin ser significativa ya que su  $p - \text{valor} = 0.63 > 0.05$  dado que las demás covariables significativas están, por lo tanto, canal no entra en el modelo.

```
Call:
coxph(formula = Surv(tiempo, evento) ~ edad + antigüedad + prodse +
      ingreso + canal, data = seguro, na.action = na.exclude, method = "breslow")

n= 1000, number of events= 513

              coef      exp(coef)    se(coef)      z Pr(>|z|)
edad          3.029e-02  1.031e+00  3.937e-03  7.694 1.42e-14 ***
antigüedad    -7.012e-02  9.323e-01  8.289e-03 -8.460 < 2e-16 ***
prodseTRUE    -5.037e-01  6.043e-01  8.952e-02 -5.627 1.83e-08 ***
ingreso       -5.346e-05  9.999e-01  9.381e-06 -5.698 1.21e-08 ***
canal         -4.228e-02  9.586e-01  8.878e-02 -0.476  0.634
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

              exp(coef) exp(-coef) lower .95 upper .95
edad          1.0308      0.9702      1.0228      1.0387
antigüedad    0.9323      1.0726      0.9173      0.9475
prodseTRUE    0.6043      1.6549      0.5070      0.7201
ingreso       0.9999      1.0001      0.9999      1.0000
canal         0.9586      1.0432      0.8053      1.1408

Concordance= 0.67 (se = 0.013 )
Likelihood ratio test= 172.1 on 5 df, p=<2e-16
Wald test = 169.1 on 5 df, p=<2e-16
Score (logrank) test = 173.2 on 5 df, p=<2e-16
```

Este conjunto de covariables representa el modelo que mejor explica el riesgo de presentar la primera reclamación, cumpliendo con todos los pasos del algoritmo requerido.

### EXTRA: INTERACCIONES

El siguiente paso consiste en evaluar interacciones entre las covariables significativas y verificar el cumplimiento del supuesto de riesgos proporcionales (Schoenfeld, log(-log), residuos Martingala), lo cual se desarrollará en esta sección.

Una vez determinado el conjunto final de covariables significativas (edad, ingreso, prodse, antigüedad, educacion), se procedió a evaluar posibles interacciones entre ellas. Esto es necesario para identificar si el efecto de una covariable sobre el riesgo puede modificarse en presencia de otra



|                      | coef       | exp(coef) | se(coef)  | z      | Pr(> z )     |
|----------------------|------------|-----------|-----------|--------|--------------|
| edad                 | 2.975e-02  | 1.030e+00 | 3.947e-03 | 7.535  | 4.87e-14 *** |
| antigüedad           | -5.812e-02 | 9.435e-01 | 1.317e-02 | -4.413 | 1.02e-05 *** |
| prodseTRUE           | -5.018e-01 | 6.054e-01 | 8.951e-02 | -5.607 | 2.06e-08 *** |
| educacion            | 2.411e-01  | 1.273e+00 | 1.071e-01 | 2.251  | 0.0244 *     |
| ingreso              | -5.496e-05 | 9.999e-01 | 9.404e-06 | -5.845 | 5.08e-09 *** |
| antigüedad:educacion | -1.165e-02 | 9.884e-01 | 9.503e-03 | -1.226 | 0.2203       |
| educacion            | 1.296e-01  | 1.138e+00 | 5.357e-02 | 2.420  | 0.015523 *   |
| ingreso              | -4.808e-05 | 1.000e+00 | 1.256e-05 | -3.827 | 0.000129 *** |
| prodseTRUE:ingreso   | -1.455e-05 | 1.000e+00 | 1.880e-05 | -0.774 | 0.438861     |

Las interacciones evaluadas fueron:

1. Edad:Prodse
2. Edad:Educacion
3. Edad:Ingreso
4. Edad:Antigüedad
5. Prodse:Educacion
6. Prodse:Ingreso
7. Prodse:Antigüedad
8. Educacion:Ingreso
9. Educacion:Antigüedad
10. Ingreso:Antigüedad

|                    | coef       | exp(coef) | se(coef)  | z      | Pr(> z )     |
|--------------------|------------|-----------|-----------|--------|--------------|
| edad               | 2.971e-02  | 1.030e+00 | 3.947e-03 | 7.529  | 5.13e-14 *** |
| antigüedad         | -7.081e-02 | 9.316e-01 | 8.294e-02 | -8.537 | < 2e-16 ***  |
| prodseTRUE         | -4.986e-01 | 6.074e-01 | 8.964e-02 | -5.563 | 2.66e-08 *** |
| educacion          | 1.975e-01  | 1.218e+00 | 1.707e-01 | 1.157  | 0.247307     |
| ingreso            | -4.959e-05 | 1.000e+00 | 1.482e-05 | -3.346 | 0.000819 *** |
| educacion:ingreso  | -4.808e-06 | 1.000e+00 | 1.114e-05 | -0.432 | 0.666002     |
| edad               | 2.972e-02  | 1.030e+00 | 3.944e-03 | 7.535  | 4.87e-14 *** |
| antigüedad         | -7.266e-02 | 9.299e-01 | 2.620e-02 | -2.774 | 0.00554 **   |
| prodseTRUE         | -5.009e-01 | 6.060e-01 | 8.951e-02 | -5.596 | 2.19e-08 *** |
| educacion          | 1.277e-01  | 1.136e+00 | 5.353e-02 | 2.386  | 0.01704 *    |
| ingreso            | -5.584e-05 | 9.999e-01 | 1.918e-05 | -2.911 | 0.00360 **   |
| antigüedad:ingreso | 1.344e-07  | 1.000e+00 | 1.712e-06 | 0.078  | 0.93744      |
| educacion          | 1.276e-01  | 1.136e+00 | 5.353e-02 | 2.385  | 0.0171 *     |
| ingreso            | -5.416e-05 | 9.999e-01 | 9.406e-06 | -5.757 | 8.54e-09 *** |
| edad:antigüedad    | -1.114e-03 | 9.989e-01 | 7.147e-04 | -1.559 | 0.1191       |
| edad               | 3.073e-02  | 1.031e+00 | 5.120e-03 | 6.001  | 1.96e-09 *** |
| antigüedad         | -7.088e-02 | 9.316e-01 | 8.307e-03 | -8.533 | < 2e-16 ***  |
| prodseTRUE         | -3.868e-01 | 6.792e-01 | 8.829e-02 | -1.010 | 0.3124       |
| educacion          | 1.268e-01  | 1.135e+00 | 5.356e-02 | 2.367  | 0.0179 *     |
| ingreso            | -5.439e-05 | 9.999e-01 | 9.424e-06 | -5.772 | 7.85e-09 *** |
| edad:prodseTRUE    | -2.419e-03 | 9.976e-01 | 7.905e-03 | -0.306 | 0.7596       |

## Metodología y Pruebas Estadísticas

Se evaluaron matemáticamente las 10 combinaciones posibles de segundo orden (pares) derivadas de las cinco variables principales. Cada interacción fue incorporada al modelo multivariado de Cox para someter su coeficiente a una prueba de hipótesis individual, evaluando si su inclusión aportaba poder explicativo adicional al modelo. El contraste de hipótesis planteado para cada interacción fue:

- $H_0$ :  $B_{\text{interacción}} \neq 0$  (La interacción no tiene un efecto significativo sobre el riesgo de cancelación).
- $H_1$ :  $B_{\text{interacción}} \neq 0$  (La interacción modifica significativamente el riesgo).

## Análisis de Resultados

Al evaluar los resultados bajo un nivel de significancia del 5% ( $\alpha = 0.05$ ), se observó el siguiente comportamiento en los p-valores asociados a cada término de interacción cruzada:

1. edad:antigüedad ( $p = 0.1191$ )
2. edad:producto ( $p = 0.7596$ )
3. edad:educacion ( $p = 0.8780$ )
4. edad:ingreso ( $p = 0.0805$ )
5. producto:educacion ( $p = 0.3260$ )
6. producto:ingreso ( $p = 0.4388$ )
7. antigüedad:producto ( $p = 0.7487$ )
8. educacion:ingreso ( $p = 0.6660$ )
9. antigüedad:ingreso ( $p = 0.9374$ )

|                      | coef       | exp(coef) | se(coef)  | z      | Pr(> z )     |
|----------------------|------------|-----------|-----------|--------|--------------|
| edad                 | 8.707e-03  | 1.009e+00 | 1.262e-02 | 0.690  | 0.49040      |
| antigüedad           | -7.137e-02 | 9.311e-01 | 8.299e-03 | -8.600 | < 2e-16 ***  |
| prodseTRUE           | -5.084e-01 | 6.014e-01 | 8.962e-02 | -5.673 | 1.4e-08 ***  |
| educacion            | 1.286e-01  | 1.137e+00 | 5.351e-02 | 2.403  | 0.01628 *    |
| ingreso              | -1.233e-04 | 9.999e-01 | 4.049e-05 | -3.046 | 0.00232 **   |
| edad:ingreso         | 1.462e-06  | 1.000e+00 | 8.367e-07 | 1.747  | 0.08059 .    |
| edad                 | 2.994e-02  | 1.030e+00 | 3.958e-03 | 7.564  | 3.92e-14 *** |
| antigüedad           | -7.078e-02 | 9.317e-01 | 8.293e-03 | -8.534 | < 2e-16 ***  |
| prodseTRUE           | -6.141e-01 | 5.411e-01 | 1.465e-01 | -4.192 | 2.77e-05 *** |
| educacion            | 8.302e-02  | 1.087e+00 | 7.005e-02 | 1.185  | 0.236        |
| ingreso              | -5.508e-05 | 9.999e-01 | 9.420e-06 | -5.847 | 5.02e-09 *** |
| prodseTRUE:educacion | 1.065e-01  | 1.112e+00 | 1.085e-01 | 0.982  | 0.326        |

10. antigüedad:educacion (p = 0.2203)

### Conclusión del Modelo Definitivo

Como se puede observar, absolutamente todos los  $p$ -valores resultaron estrictamente mayores al nivel de significancia ( $\alpha = 0.05$ ). En consecuencia, no existe evidencia estadística suficiente para rechazar la hipótesis nula en ninguna de las combinaciones evaluadas.

Desde una perspectiva actuarial y apelando al principio de parsimonia, se concluye que la complejidad adicional de incluir términos cruzados no está justificada por los datos. La dinámica de cancelación de contratos de esta cartera se explica de manera óptima y suficiente a través de los efectos individuales y directos de la edad del cliente, su antigüedad, el tipo de producto adquirido, su nivel de ingresos y su nivel educativo. Por lo tanto, el modelo de riesgos proporcionales de Cox final prescinde de interacciones y se consolida únicamente con los efectos principales.

### Paso 4. Riesgos Proporcionales

El modelo de Cox requiere que las covariables cumplan el supuesto de riesgos proporcionales (PH). Para validar este supuesto, se emplearon los residuos de Schoenfeld, tanto de manera individual como en forma global, evaluando las siguientes hipótesis:

$H_0$ : Las covariables del modelo presentan riesgos proporcionales

$H_1$ : Las covariables del modelo NO presentan riesgos proporcionales

Con un nivel de significancia de  $\alpha = 0.05$ , los resultados fueron los siguientes: Se observa en la imagen anterior que la prueba de hipótesis global tiene un  $p$ -valor = 0.77 > 0.05, por lo que no se rechaza la hipótesis nula, es decir que no hay evidencia suficiente en contra de que el modelo tiene riesgos proporcionales. De igual manera en la misma imagen, se aprecian los  $p$ -valores correspondientes a cada covariable individualmente las cuales son mayores que 0.05, por lo que tampoco se rechaza la hipótesis nula en sus pruebas de hipótesis individuales. Esto indica que no existe evidencia en contra del supuesto de riesgos proporcionales, por lo que el modelo de Cox es adecuado y válido bajo este criterio.

|            | chisq | df | p    |
|------------|-------|----|------|
| edad       | 0.460 | 1  | 0.50 |
| antigüedad | 0.036 | 1  | 0.85 |
| prodse     | 1.291 | 1  | 0.26 |
| educacion  | 0.344 | 1  | 0.56 |
| ingreso    | 0.277 | 1  | 0.60 |
| GLOBAL     | 2.542 | 5  | 0.77 |

Análisis de Residuales

La **FIGURA 3** exhibe los residuos de Schoenfeld escalados para las covariables del modelo final. Se observa una dispersión aleatoria sin tendencias sistemáticas, donde las curvas suavizadas convergen consistentemente hacia la horizontalidad sobre el eje cero, lo cual respalda visualmente el cumplimiento del supuesto de **riesgos proporcionales**. Si bien se aprecian ligeras fluctuaciones en los extremos, estas se consideran ruidos estocásticos propios de la muestra y no representan una transgresión al modelo. Esta evidencia gráfica es corroborada analíticamente mediante la prueba formal de Schoenfeld, donde la totalidad de los p-valores individuales excedieron el umbral de 0.05 y la prueba global alcanzó un **p-valor de 0.77**, confirmando de manera concluyente la validez del supuesto para el análisis.




FIGURA 3

### Validación de Linealidad (Residuos de Martingala)

Para validar la correcta especificación funcional de las covariables numéricas dentro del modelo de Cox, se analizó el comportamiento de los residuos de Martingala frente a las variables continuas: edad, ingreso y antigüedad (excluyendo a prodse y educacion por su naturaleza categórica). Este diagnóstico gráfico permite evaluar si la relación entre cada covariable y el logaritmo del riesgo es efectivamente lineal, o si, por el contrario, requiere alguna transformación matemática.

Como se ilustra en la **FIGURA 4**, las curvas suavizadas superpuestas a los residuos exhiben una tendencia predominantemente horizontal y cercana a cero, sin trazar patrones curvilíneos pronunciados. Al no existir evidencia visual de desviaciones sistemáticas o violaciones al supuesto de linealidad, se justifica estadísticamente la conservación de las tres covariables numéricas en su forma lineal original dentro del modelo definitivo.




FIGURA 4

### Analizando datos influyentes (outliers)

Se evaluó la existencia de datos influyentes mediante **residuos de devianza y martingala**. En la **FIGURA 5**, aunque se detectaron valores aislados, su falta de persistencia sistemática entre covariables confirma que **no afectan el ajuste global del modelo**. Al ser variaciones normales en datos de supervivencia, no se requiere realizar correcciones o exclusiones, manteniendo la validez del modelo original.




FIGURA 5

### FUNCION RIESGO BASE Y COMPARACION DE MODELOS

La siguiente **FIGURA 6** muestra la estimación escalonada de la función de riesgo base  $h_0(t)$  del modelo de Cox, obtenida mediante el método de Breslow. Su utilidad principal es permitir calcular la supervivencia base  $S_0(t)$  y, a partir de ella, las curvas de supervivencia ajustadas para diferentes perfiles de covariables.

Visualmente, el riesgo base "sube un escalón" únicamente en los instantes exactos en los que se registra un evento o fallo en la base de datos, mientras que las secciones horizontales o "partes planas" indican periodos de tiempo sin cancelaciones donde el riesgo permanece constante. Es importante destacar que el propósito de esta gráfica no es evaluar la significancia de las covariables ni los cambios en sus efectos, sino servir como el componente esencial para calcular la supervivencia base  $S_0$ , permitiendo así la construcción y comparación técnica de las curvas de supervivencia finales para los diversos perfiles de clientes del portafolio actuarial.




FIGURA 6

$$h(t, \vec{X}) = h_0(t) \exp \{ \beta_{edad} * edad + \beta_{prodse} * prodse + \beta_{educacion} * educacion + \beta_{antigüedad} * antigüedad + \beta_{ingreso} * ingreso \}$$

Desde las estimaciones del modelo cox, obtenemos lo siguiente:

$$h(t, \vec{X}) = h_0(t) \exp \{ 0.02973 * edad - 0.5008 * prodse + 0.12775 * educacion - 0.07071 * antigüedad + 0.00005453 * ingreso \}$$

donde



$$(\vec{X}) = (\text{edad}, \text{prodse}, \text{educacion}, \text{antigüedad}, \text{ingreso})$$

### COMPARACIÓN DE MODELOS

Sea  $(\vec{X}) = (45, 1, 0, 10, 15150)$  como el grupo 1 de personas de 45 años, con 10 años de relación con la institución e ingreso de \$15,150 (una persona con edad, antigüedad e ingreso promedio) **con educación baja y adquirieron el producto de seguro**, y para el grupo 2 consideraremos **la misma edad, ingreso, producto y antigüedad pero con educación alta**  $(\vec{X}) = (45, 1, 2, 10, 15150)$ , También consideremos el grupo 3 y 4 donde la edad, antigüedad, ingreso y la educación es promedio y únicamente compararemos entre el tipo de producto, donde el grupo 3 tiene el producto “seguro” y el grupo 4 el producto “ahorro”.

Calculamos lo siguiente  $\frac{h(t, \vec{X}_1)}{h(t, \vec{X}_2)} = 0.7745 < 1$      $\frac{h(t, \vec{X}_3)}{h(t, \vec{X}_4)} = 1.65 > 1$

El grupo 1 tiene menor riesgo que el grupo 2, de hecho, el riesgo en un tiempo  $t$  para el grupo que tiene educación **baja es 0.7745 veces el riesgo** del grupo 2 con educación alta. Es decir, la probabilidad de no tener una cancelación anticipada hasta tiempo  $t$  (supervivencia hasta  $t$ ) es mayor para el grupo 1 que para el grupo 2, siempre que edad, antigüedad, ingreso y el producto sean iguales en ambos perfiles. Análogamente, observamos que el grupo 4 tiene menor riesgo que el grupo 3, de hecho, el riesgo en un tiempo  $t$  para el grupo con el producto “seguro” **tiene 1.65 veces el riesgo** de la cancelación anticipada de contrato que el grupo que contrato el producto “ahorro”.